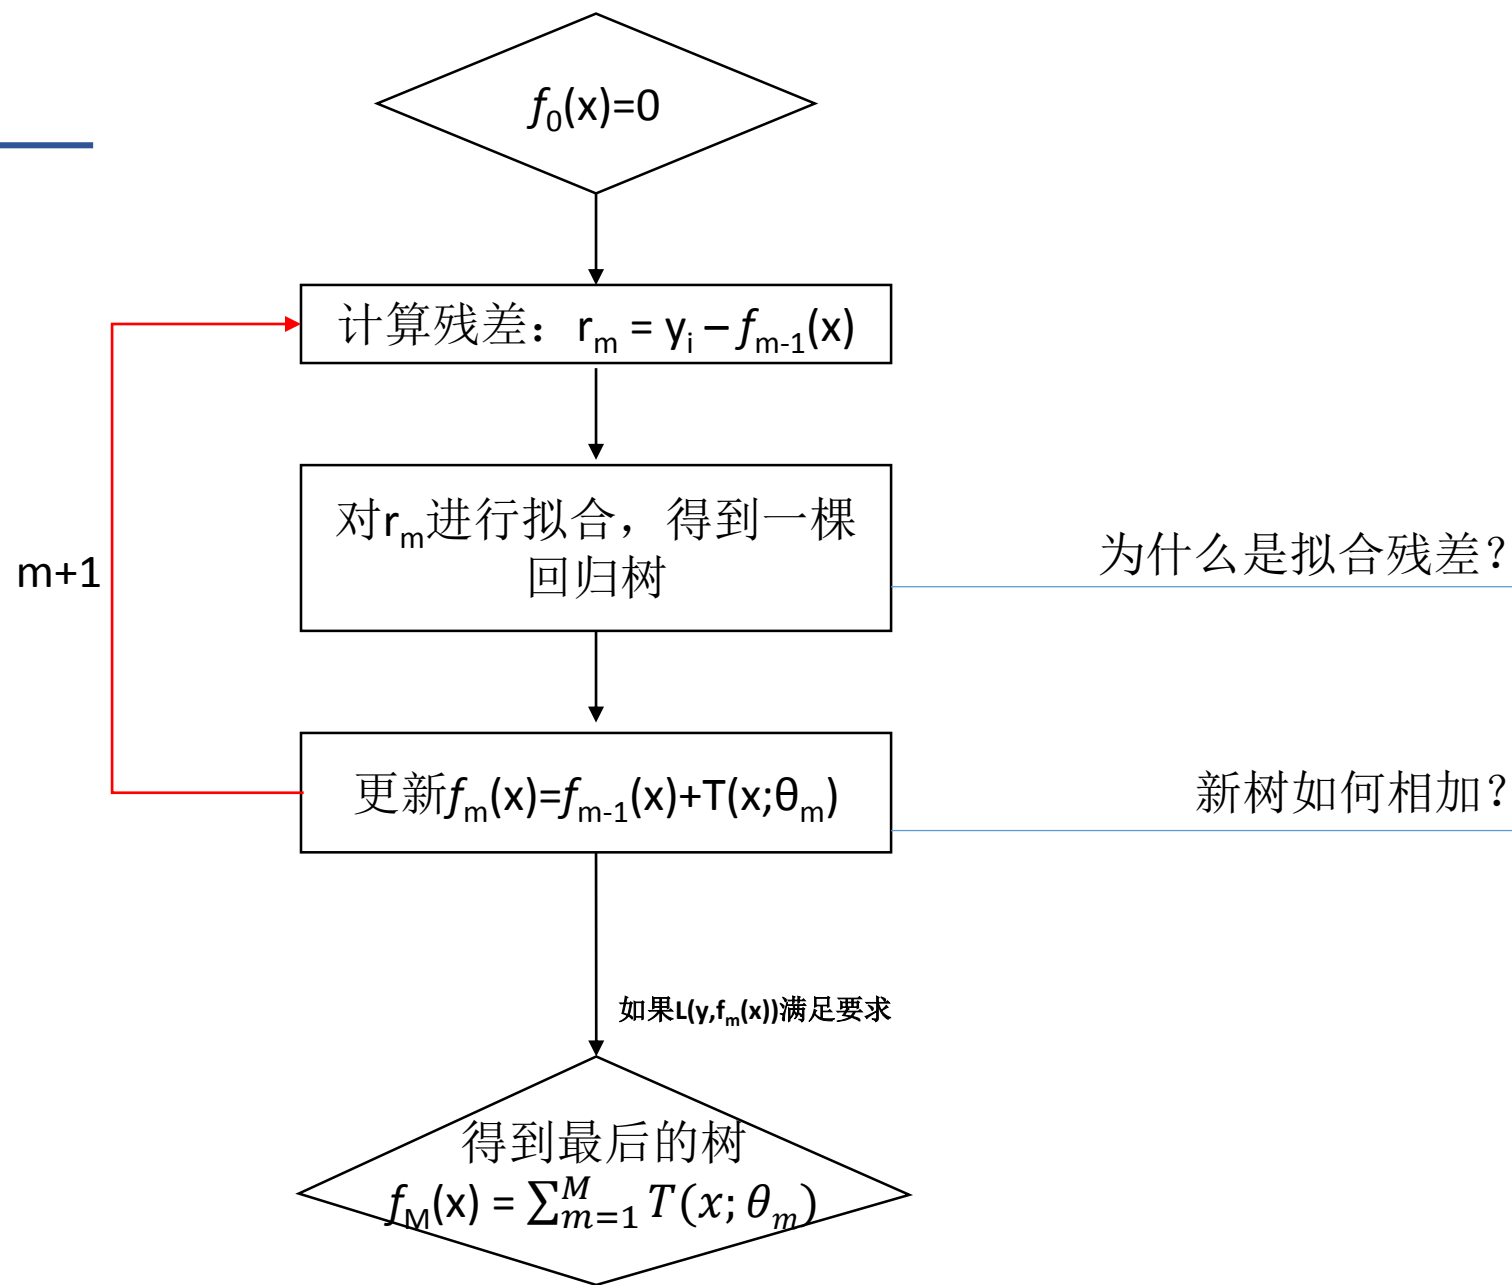


从提升到xgboost

jhs
2018/09/04


提升术



为什么是拟合残差？

$$f_M(x) = \sum_{m=1}^M T(x; \theta_m)$$

$$\hat{\theta}_m = \operatorname{argmin}_{\theta_m} \sum_{i=1}^N L(y_i, f_{m-1}(x_i) + T(x_i, \theta_m))$$

$$\begin{aligned} L(y, f_m(x)) &= (y - f_m(x))^2 \\ &= L[y, f_{m-1}(x) + T(x; \theta)]^2 \\ &= [y - f_{m-1}(x) - T(x; \theta)]^2 \end{aligned}$$


故，损失函数写为：

$$L[r_{m-1}, T(x; \theta)]^2$$

r_{m-1} 的值，用于第m轮的拟合

树们如何相加？

$$T_1(x) = \begin{cases} 6.24, & x < 6.5 \\ 8.91, & x \geq 6.5 \end{cases}$$

$$f_1 = f_0 + T_1(x; \theta)$$

$$f_1(x) = \begin{cases} 6.24, & x < 6.5 \\ 8.91, & x \geq 6.5 \end{cases}$$

$$T_2(x) = \begin{cases} -0.52, & x < 3.5 \\ 0.22, & x \geq 3.5 \end{cases}$$

$$f_2 = f_1 + T_2(x; \theta)$$

$$f_2(x) = \begin{cases} 5.72, & x < 3.5 \\ 6.46, & 3.5 \leq x < 6.5 \\ 9.13, & x \geq 6.5 \end{cases}$$

$$T_3(x) = \begin{cases} 0.15, & x < 6.5 \\ -0.22, & x \geq 6.5 \end{cases}$$

$$T_4(x) = \begin{cases} -0.16, & x < 4.5 \\ 0.11, & x \geq 4.5 \end{cases}$$

$$T_5(x) = \begin{cases} 0.07, & x < 6.5 \\ -0.11, & x \geq 6.5 \end{cases}$$

$$T_6(x) = \begin{cases} -0.15, & x < 2.5 \\ 0.04, & x \geq 2.5 \end{cases}$$

树们如何相加？

$$\begin{aligned} f_6(x) &= f_5(x) + T_6(x) \\ &= T_1(x) + T_2(x) + T_3(x) + T_4(x) + T_5(x) + T_6(x) \end{aligned}$$

$$T_1(x) = \begin{cases} 6.24, & x < 6.5 \\ 8.91, & x \geq 6.5 \end{cases}$$

$$T_2(x) = \begin{cases} -0.52, & x < 3.5 \\ 0.22, & x \geq 3.5 \end{cases}$$

$$T_3(x) = \begin{cases} 0.15, & x < 6.5 \\ -0.22, & x \geq 6.5 \end{cases}$$

$$T_4(x) = \begin{cases} -0.16, & x < 4.5 \\ 0.11, & x \geq 4.5 \end{cases}$$

$$T_5(x) = \begin{cases} 0.07, & x < 6.5 \\ -0.11, & x \geq 6.5 \end{cases}$$


$$T_6(x) = \begin{cases} -0.15, & x < 2.5 \\ 0.04, & x \geq 2.5 \end{cases}$$

	1	2	3	4	5	6	7	8	9	10
T1	1,2,3,4,5,6 --> 6.24						7,8,9,10 --> 8.91			
T2	1,2,3 --> -0.52			4,5,6,7,8,9,10 --> 0.22						
T3	1,2,3,4,5,6 --> -0.15						7,8,9,10 --> -0.22			
T4	1,2,3,4 --> -0.16				5,6,7,8,9,10 --> 0.11					
T5	1,2,3,4,5,6 --> 0.07						6,7,8,9,10 --> -0.11			
T6	1,2 --> -0.15		3,4,5,6,7,8,9,10 --> 0.04							

同时计算出
L1 , L2 , L3 , L4 , L5 , L6

树们如何相加？

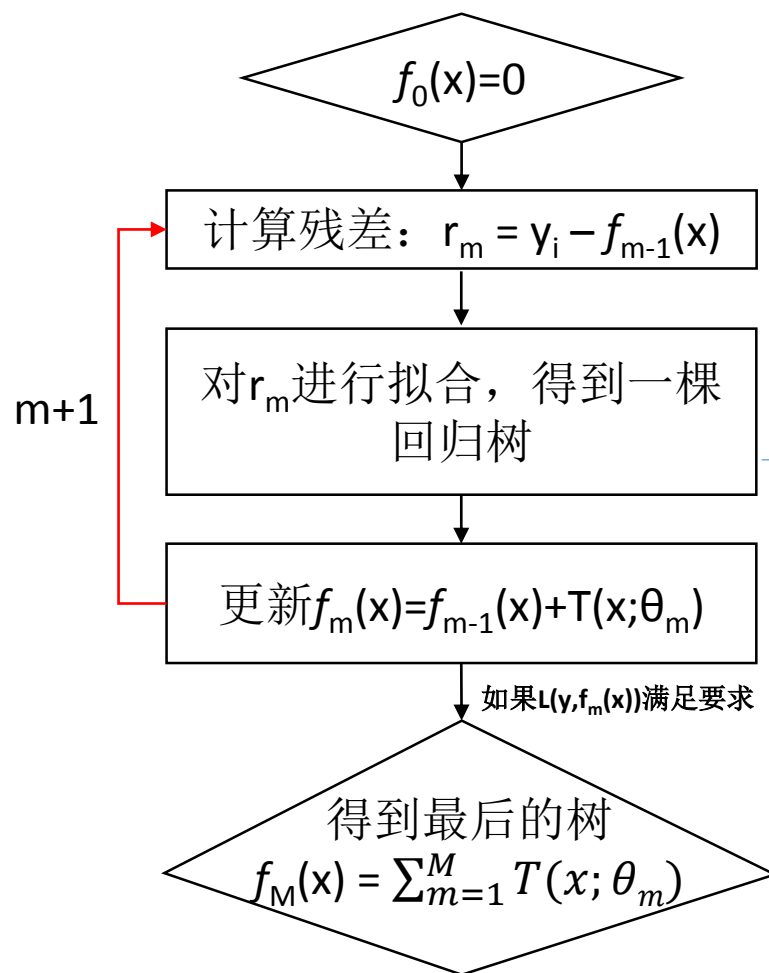
$$\begin{aligned} f_6(x) &= f_5(x) + T_6(x) \\ &= T_1(x) + T_2(x) + T_3(x) + T_4(x) + T_5(x) + T_6(x) \end{aligned}$$



$$F(x) = f_6(x) = \begin{cases} 5.63, & x < 2.5 \\ 5.82, & 2.5 \leq x < 3.5 \\ 6.56, & 3.5 \leq x < 4.5 \\ 6.83, & 4.5 \leq x < 6.5 \\ 8.95, & x \geq 6.5 \end{cases}$$

此时， $L(y, f_6(x)) = 0.17$
我们假设此时已经满足要求，
就不在继续计算下去了

GBDT的GB(Gradient Boosting)



$$\begin{aligned} L(y, f_m(x)) &= (y - f_m(x))^2 \\ &= L[y, f_{m-1}(x) + T(x; \theta)]^2 \\ &= [y - f_{m-1}(x) - T(x; \theta)]^2 \\ &= [r_{m-1} - T(x; \theta)]^2 \end{aligned}$$

$$r_m = -\left[\frac{\partial L(y, f(x))}{\partial f(x)}\right]_{f(x)=f_{m-1}(x)}$$

利用损失函数的负梯度在当前模型的值，
作为回归问题提升术算法中残差的近似值

这里需要注意的是，前面我们提到一个算法步骤是Line search（具体见论文）。在GBDT里，我们通过不会直接把上一个轮的预测值 $F_{m-1}(x)$ 直接加上 $\sum_{j=1}^J \gamma_{jm} I(x_i \in R_{jm})$ ，而是会在 $\sum_{j=1}^J \gamma_{jm} I(x_i \in R_{jm})$ 乘上一个学习率。可以理解，因为如果每次完全加上（学习率为1）本轮模型的预测值容易导致过拟合。所以通常在GBDT中的做法（也叫Shrinkage）

GBDT的算法流程

输入： $(x_i, y_i), T, L$

1. 初始化 f_0

2. for t = 1 to T do

2.1 计算响应：

$$\tilde{y}_i = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x)=F_{t-1}(x)}, i=1,2,\dots,N$$

2.2 学习第t棵树：

$$w^* = \arg \min_w \sum_{i=1}^N \left(\tilde{y}_i - h_t(x_i; w) \right)^2$$

2.3 line search找步长：

$$\rho^* = \arg \min_{\rho} \sum_{i=1}^N L(y_i, F_{t-1}(x_i) + \rho h_t(x_i; w^*))$$

2.4 令 $f_t = \rho^* h_t(x; w^*)$

更新模型：

$$F_t = F_{t-1} + f_t$$


3. 输出 F_T

xgboost

Xgboost仍然是基于boosting的思想，但是在实现过程中，其所需要优化的目标函数有所变化。

Xgboost的目标函数：

$$\text{Obj}(\theta) = L(\theta) + \Omega(\theta)$$



损失函数



正则化项

损失函数

$$y_i^t = y_i^{t-1} + f_t(x_i)$$

$$\mathcal{L}^t = \sum_{i=1}^n l(y_i, y_i^{t-1} + f_t(x_i))$$

泰勒公式:

$$f(x + \Delta x) \approx f(x) + \underline{f'(x)\Delta x} + \frac{1}{2} \underline{f''(x)\Delta x^2} + o(\Delta x^3)$$

令

$$g_i = \frac{\partial L(y_i, y_i^{t-1})}{\partial y_i^{t-1}}$$

$$h_i = \frac{\partial^2 L(y_i, y_i^{t-1})}{\partial y_i^{t-1}}$$

$$\text{则, } \mathcal{L}^t = \sum_{i=1}^n \left[L(y_i, y_i^{t-1}) + g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right]$$

目标函数作变换

$$L^t = \sum_{i=1}^n l(y_i, y_i^{t-1} + f_t(x_i)) + \Omega(f_t)$$

$$L'^t = \sum_{i=1}^n \left[\underbrace{L(y_i, y_i^{t-1})}_{\text{均为已知, 故舍去}} + g_i(x_i)f_t(x_i) + \frac{1}{2}h_i f_t^2(x_i) \right] + \Omega(f_t)$$

均为已知, 故舍去

$$L'^t = \sum_{i=1}^n \left[g_i(x_i)f_t(x_i) + \frac{1}{2}h_i f_t^2(x_i) \right] + \Omega(f_t)$$

$$= \sum_{i=1}^n \left[g_i w_{q(x_i)} + \frac{1}{2}h_i w_{q(x_i)}^2 \right] + \gamma T + \lambda \frac{1}{2} \sum_{j=1}^T w_j^2$$

对样本累加

对叶子累加

把 $f_t, \Omega(f_t)$ 写成树结构的形式, 即把下式代入目标函数中

$$f(\mathbf{x}) = w_{q(\mathbf{x})} \quad \Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|^2$$

$$= \sum_{j=1}^T \left[\sum_{i \in I_j} g_{m,i} w_j + \frac{1}{2} \sum_{i \in I_j} h_{m,i} w_j^2 + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \right] + \gamma T$$

$$= \sum_{j=1}^T \left[\underbrace{\sum_{i \in I_j} g_{m,i}}_{G_j} w_j + \frac{1}{2} \left(\underbrace{\sum_{i \in I_j} h_{m,i}}_{H_j} + \lambda \right) w_j^2 \right] + \gamma T$$

$$= \sum_{j=1}^T \left[G_j w_j + \frac{1}{2} (H_j + \lambda) w_j^2 \right] + \gamma T$$

$$\mathcal{L}'^t = \sum_{j=1}^T \left[G_j w_j + \frac{1}{2} (H_j + \lambda) w_j^2 \right] + \gamma T$$

假如，树的结构（ $q(x)$ ）确定，为了使目标函数最小，
可以令其导数为0，解得每个叶节点的最优预测分数为：

$$w_j^* = -\frac{G_j}{H_j + \lambda}$$

代入，得：

$$\mathcal{L}'^t = -\frac{1}{2} \sum_{j=1}^T \frac{G_j^2}{H_j + \lambda} + \gamma T$$

填坑

把 $f_t, \Omega(f_t)$ 写成树结构的形式，即把下式代入目标函数中

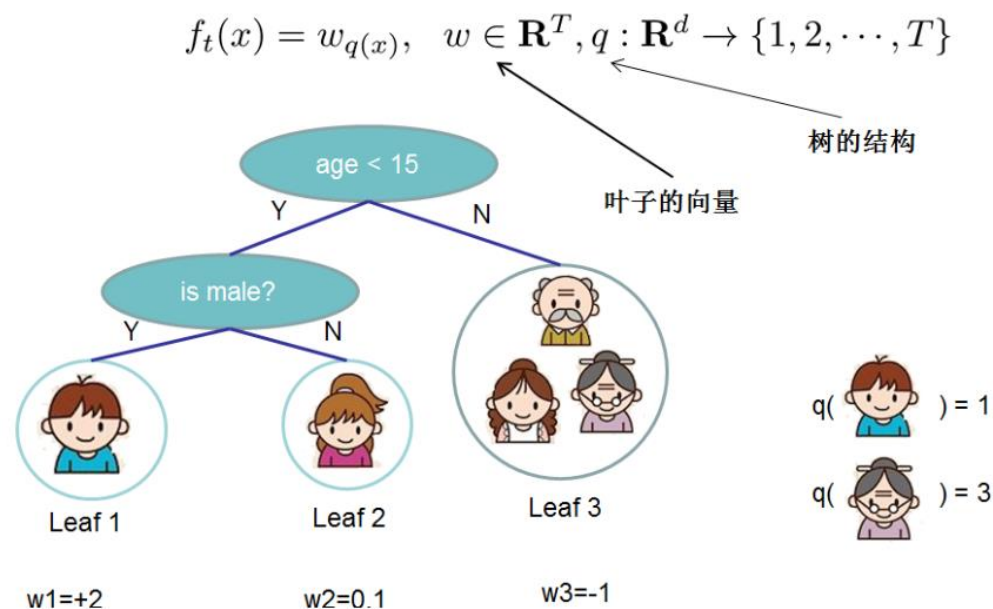
$$f(\mathbf{x}) = w_{q(\mathbf{x})} \quad \Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|^2$$

树的定义：

把树拆分成结构部分 q 和叶子分数部分 w

$$\phi(\mathbf{x}) = w_{q(\mathbf{x})}, \quad \mathbf{w} \in \mathbb{R}^T, q: \mathbb{R}^D \rightarrow \{1, \dots, T\}$$

- 结构函数 q ：把输入映射到叶子的索引号
- w ：给出每个索引号对应的叶子的分数
- T 为树中叶子结点的数目， D 为特征维数



正则项

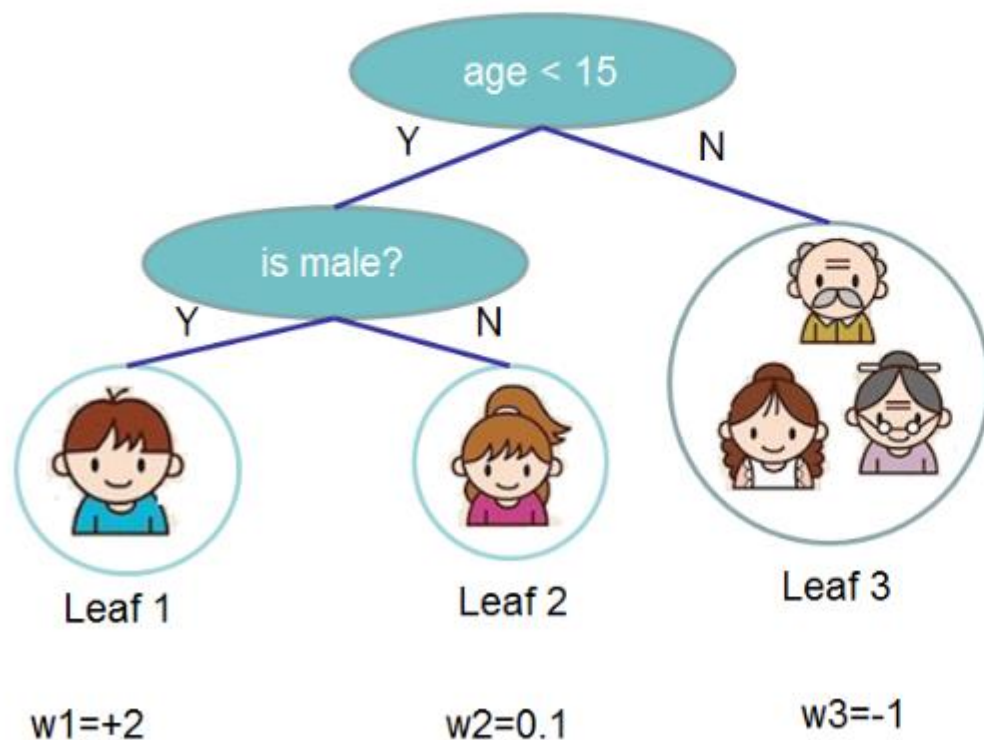
- XGBoost的目标函数（函数空间）

$$\mathcal{L}(\phi) = \sum_i l(\hat{y}_i, y_i) + \sum_k \Omega(f_k)$$

正则项对每棵回归树的复杂度进行了惩罚

- 相比原始的GBDT，XGBoost的目标函数多了正则项，使得学习出来的模型更加不容易过拟合。

$$\Omega(f_t) = \underbrace{\gamma T}_{\text{叶子的个数}} + \frac{1}{2} \lambda \underbrace{\sum_{j=1}^T w_j^2}_{\text{w的L2模平方}}$$



$$\Omega = \gamma 3 + \frac{1}{2} \lambda (4 + 0.01 + 1)$$

未涉及的内容

- 如何建树？
 - 树节点的分裂
 - 稀疏值的处理
- 特征的重要性

Reference

- 1. 《统计学习方法》 李航. 清华大学出版社
- 2. 《XGBoost 从基础到实战》 冒**.CSDN
- 3. 《机器学习 升级版V》 邹博.chinahadoop.cn
- 4. 《GBDT 算法原理与系统设计简介》 wepon
- 5. 《GBDT原理与Sklearn源码分析-回归篇》 kingsam_
https://blog.csdn.net/qq_22238533/article/details/79185969
- 6. 《GBDT原理与Sklearn源码分析-分类篇》 kingsam_
https://blog.csdn.net/qq_22238533/article/details/79192579

- 水平有限，如有错误或不当之处，恳请批评指正！
- 517949233@qq.com